AdaptGov: aprendizado de política fiscal adaptativa em um modelo macroeconômico baseado em agentes

Daniel Andrade

Outubro de 2026

1 Introdução, objetivos e justificativa

1.1 Introdução

Um sistema complexo é caracterizado por possuir muitos agentes que interagem produzindo comportamentos emergentes, ou seja, que não podem ser trivialmente derivados a partir de suas características individuais (Newman, 2011). A economia é um sistema complexo onde bilhões de agentes heterogêneos, entre trabalhadores, empresas, bancos e instituições governamentais, interagem em compras e vendas, empréstimos, pagamentos, investimentos, resultando em fenômenos emergentes como preços, inflação e crescimento. Além disso, esses atores aprendem e evoluem ao longo do tempo, o que modifica fundamentalmente a estrutura do sistema, tornando-o adaptativo (Arthur, 2013).

A aplicação da lente teórica de sistemas complexos adaptativos para o estudo da economia tem se mostrado uma alternativa promissora ao paradigma predominante da teoria econômica, o neoclássico, que se ancora em pressupostos teóricos pouco críveis, como a existência de um equilíbrio geral, as expectativas racionais e os agentes representativos (Gallegati e Kirman, 2012).

Os modelos baseados em agentes ("ABMs") têm se constituído em uma ferramenta poderosa para o estudo da economia complexa através de ferramentas computacionais (Dawid e Delli Gatti, 2018). Neles, os agentes são simulados por meio de regras comportamentais que regem tanto seu comportamento individual quanto suas interações, sem a necessidade de um controle central. As variáveis agregadas resultantes emergem como resultado computacional dos comportamentos e interações, sem a utilização de pressupostos de informação e racionalidade perfeita ou de equilíbrio.

O trabalho proposto por Poledna et al. (Poledna et al., 2023) é um modelo baseado em agentes para a macroeconomia, ou seja, focado no estudo de propriedades agregadas da economia, como inflação, PIB, crescimento, desemprego (Dawid e Delli Gatti, 2018). O modelo foi calibrado para a Áustria, que é um país pequeno, industrial e com economia aberta. Ele se ancora nas estatísticas nacionais e em regras autorregressivas de primeira ordem, realizando previsões macroeconômicas comparáveis aos modelos DSGE ("Dynamic Stochastic General Equilibrium"), que representam o paradigma atual da macroeconomia neoclássica. O BeforeIT.jl (Glielmo et al., 2025) oferece uma implementação aberta e extensível deste modelo na linguagem Julia feita pela equipe de tecnologia da

informação do Banco da Itália. Nos trabalhos apresentados, a política fiscal é constituída majoritariamente como parâmetros fixos que delimitam impostos, benefícios sociais e gastos do governo. Nesse sentido, há espaço para o estudo de uma política fiscal variável e adaptativa, ou seja, que reage ao estado do modelo.

Também no campo dos ABMs para macroeconomia, trabalhos recentes têm utilizado inteligência artificial ("IA"), como em (Zheng et al., 2022) e (Brusatin et al., 2024), onde técnicas de aprendizado por reforço são utilizadas para treinar agentes com comportamentos racionais e avaliar o resultado macroeconômico. Em (Li et al., 2024) LLMs ("Large Language Models") fazem o papel de consumidores e trabalhadores em um modelo que busca reproduzir qualitativamente fatos estilizados macroeconômicos.

Por outro lado, a análise de sensibilidade e os metamodelos têm se constituído em ferramentas importantes para a avaliação e emulação de ABMs em diversas áreas, pois podem auxiliar na avaliação da robustez e da explicabilidade dos resultados dos modelos em questão como pode ser visto em (Angione et al., 2022).

Por ser um modelo aberto, extensível, calibrado para as estatísticas nacionais e com desempenho preditivo similar aos DSGEs nos testes dos autores, o BeforeIT.jl é um campo fértil para investigar políticas fiscais em um modelo macroeconômico baseado em agentes. Este trabalho propõe realizar análises de sensibilidade dos parâmetros fiscais e treinar com aprendizagem por reforço uma política fiscal adaptativa. Essa política será comparada a configurações de parâmetros fixos com relação a indicadores de bem-estar definidos, medidos através de uma função de recompensa, que combina PIB, desemprego, inflação, dívida e déficit. Assim, busca-se avaliar se a adaptação da política fiscal melhora o resultado das simulações e em quais casos. Esse tipo de exploração pode ser um passo importante para tornar o BeforeIT.jl e outros ABMs macroeconômicos úteis ao auxiliar tomadores de decisões governamentais na formulação de políticas públicas.

1.2 Perguntas de Pesquisa

Pergunta central

No modelo BeforeIT.jl calibrado para a Áustria, uma política fiscal adaptativa treinada com aprendizado por reforço proporciona maior bem-estar que políticas de parâmetros fixos, considerando referências fiscais de dívida e déficit inspiradas nas regras europeias?

Perguntas secundárias

- Quais alterações nos parâmetros da política fiscal produzem resultados estatisticamente significantes?
- Quais estratégias adaptativas emergem a partir do treinamento de uma política fiscal com aprendizagem por reforço?
- Em quais cenários os resultados de uma política fiscal adaptativa superam as regras fixas e políticas fiscais segundo uma função de bem-estar bem definida?

1.3 Justificativa

Modelos baseados em agentes são uma ferramenta poderosa para a análise da macroeconomia com o potencial de informar a sociedade e agências governamentais sobre o comportamento passado e futuro de indicadores-chave como inflação, desemprego, crescimento (Arthur, 2013; Gallegati e Kirman, 2012; Dawid e Delli Gatti, 2018).

Além disso, os modelos baseados em agentes têm tido sua fronteira explorada através da utilização de inteligência artificial para a construção de agentes adaptativos que aprendem ao longo da simulação (Brusatin et al., 2024; Zheng et al., 2022). Adicionalmente, a análise de sensibilidade é uma ferramenta importante para avaliar a validade, explicabilidade e robustez dos modelos em questão (Angione et al., 2022).

O trabalho busca explorar um modelo macroeconômico baseado em agente, desenvolvendo, validando e interpretando políticas fiscais adaptativas treinadas através de aprendizagem por reforço, ampliando o uso do modelo para análises de política fiscal.

1.4 Objetivos

Objetivo geral:

Desenvolver e avaliar políticas fiscais adaptativas no modelo BeforeIT.jl, calibrado para a Áustria, através de técnicas de análise de sensibilidade e aprendizagem por reforço, comparando-as com políticas de parâmetros fixos, quanto a bem-estar, dívida pública e estabilidade macroeconômica.

Objetivos específicos:

- Formular o problema de política fiscal no contexto do modelo BeforeIT.jl, com seus parâmetros, variáveis livres e restrições.
- Realizar análise de sensibilidade nas variáveis de estudo do problema fiscal quantificando seus efeitos nos indicadores de avaliação selecionados.
- Propor, treinar e avaliar um modelo de aprendizado por reforço para a política fiscal.
- Avaliar e interpretar os resultados considerando bem-estar, dívida pública e estabilidade macroeconômica.

2 Revisão bibliográfica

Este trabalho se insere na agenda de uso de modelos baseados em agentes para estudar políticas macroeconômicas. Como sintetizam Dawid e Delli Gatti (2018), esses modelos estudam a dinâmica das variáveis agregadas da economia, calculadas pela soma de quantidades individuais de agentes heterogêneos que interagem entre si (abordagem *bottom-up*). Assim, como é amplamente demonstrado na revisão, os modelos macroeconômicos baseados em agentes oferecem um rico campo para o estudo da política econômica, seja ela fiscal, monetária ou regulatória.

O trabalho de Dosi et al. (2015) compara regras fiscais em uma economia simulada sujeita a crises e mostra que, naquele modelo, regras restritivas podem reduzir a atividade sem

melhorar as contas públicas. Já Poledna et al. (2023) foi construído um ABM de previsão macroeconômica para a economia da Áustria. Glielmo et al. (2025) esse trabalho foi adaptado para a linguagem Julia e disponibilizado de maneira open source.

Adicionalmente, esta pesquisa se ancora na recente literatura que aplica técnicas de inteligência artificial em ABMs macroeconômicos. Zheng et al. (2022) e Brusatin et al. (2024) usam aprendizagem por reforço para, respectivamente, desenhar impostos e treinar firmas em um modelo macroeconômico e Li et al. (2024) usam modelos de linguagem para simular decisões de trabalho e consumo.

3 Modelo de referência

As principais motivações do modelo BeforeIT.jl são:

- Realizar previsões macroeconômicas utilizando modelagem baseada em agentes.
- Construir uma modelagem verossimilhante, calibrando o modelo de acordo com as estatísticas governamentais e executando a simulação com escala 1:1 da população do país.

O modelo inicial foi calibrado para a economia da Áustria, que é um país pequeno e altamente integrado com a economia externa ($\approx 9M$ habitantes e $\approx 50\%$ do PIB em importações/exportações). Os agentes do modelo são famílias ativas e inativas, empresas e empresários, governo, um banco comercial, um banco central e empresas estrangeiras.

Cada etapa temporal do modelo equivale a um trimestre. As etapas-chave que levam o modelo de t para $t + 1$ são:

1. **Formação de expectativas coletivas:** nesta etapa é realizada uma regressão de primeira ordem para a previsão do PIB e da inflação. Essas previsões são utilizadas pelos diversos agentes, como empresas para estimar a produção do próximo ciclo e consumidores para estimar a renda do próximo ciclo.
2. **Execução dos choques exógenos:** são sorteados choques exógenos que modelam demanda e oferta do resto do mundo, ou seja, que quantificam as importações e exportações, bem como a inflação da zona do euro.
3. **Execução dos mercados de crédito e trabalho:** nesta etapa as empresas, após determinarem seus planos de produção, determinam o quanto querem de crédito do banco comercial. O banco então fornece crédito em uma ordem aleatória às empresas, obedecendo às regras regulatórias de fornecimento de crédito. Depois, as empresas determinam quantos trabalhadores serão contratados ou demitidos, selecionados aleatoriamente.
4. **Execução dos mercados de bens:** inicialmente o mercado intra-empresas é executado através do mecanismo de busca e pareamento, onde, para cada bem desejado, a empresa consumidora é selecionada aleatoriamente e os fornecedores são selecionados com probabilidade proporcional ao seu preço e tamanho. O mesmo processo é então repetido para os consumidores finais e empresas de bens de consumo.

5. **Atualização da contabilidade:** são atualizados os preços, rendas, saldos, impostos e agregados econômicos.

4 Metodologia e plano de atividades

Política Fiscal Adaptativa

A pesquisa será baseada em simulações computacionais do modelo BeforeIT.jl calibrado para a Áustria. Os resultados da simulação no tempo t, representados por $\mathbf{y}_t$, dependem dos parâmetros θ, do vetor de variáveis de estado iniciais $\mathbf{x}_0$ e dos choques aleatórios ε_t:

$$\mathbf{x}_{t+1} = F(\mathbf{x}_t, \theta, \varepsilon_{t+1}), \qquad \mathbf{y}_t = g(\mathbf{x}_t).$$

O agente governamental adaptativo terá como objetivo maximizar a soma da sua função de recompensa descontada ao longo do tempo:

$$S = \sum_{t=1}^{t_{\text{sim}}} \gamma^t r_t$$

Assim, a recompensa em cada etapa temporal r_t será uma função do espaço de estados do modelo y_t. A modelagem de aprendizado por reforço será baseada na proposta de (Brusatin et al., 2024), utilizado o algoritmo padrão de Q-learning, com uma política de eploração ε-greedy. O agente terá um espaço de estado $\mathcal{S}$ e espaço de ação discretos $\mathcal{A}$, e aprenderá a função de valor $Q : \mathcal{S} \times \mathcal{A} \to \mathbb{R}$, utilizando a equação de Bellman para estimar seu retorno esperado, dado um espaço de estado e possíveis ações (s, a).

O agente governamental terá como seu espaço de estados observações dos principais agregados econômicos de interesse para a política fiscal, como função do espaço de estados geral do modelo $\mathbf{y}_t$. A saber:

$$\mathbf{s}_t = f(\mathbf{y}_t) = \left(Y_t^{\text{real}},\, u_t,\, \pi_t,\, d_t,\, b_t\right).$$

- Y_t^{real}: PIB real no trimestre t;
- u_t: taxa de desemprego;
- π_t: taxa de inflação;
- d_t: déficit público acumulado nos últimos quatro trimestres dividido pelo PIB nominal acumulado no mesmo período;
- b_t: dívida pública ao fim do trimestre t dividida pelo PIB nominal anualizado a partir de até quatro trimestres;

Esse espaço de estado será discretizado para o treinamento do Q-learning, utilizando n_S divisões espaçadas entre um mínimo $S_{\min}$ e um máximo $S_{\max}$. Cada valor real de observação será aproximado ao valor discreto mais próximo.

Para o espaço de ações, foi selecionado o conjunto dos parâmetros θ que interessam à política fiscal e que tipicamente estão sob controle da política fiscal, ou seja, dos impostos e gastos públicos. A saber:

$$p_t = \left(\tau_t^{\text{INC}}, \tau_t^{\text{VAT}}, \theta_t^{\text{UB}}, \log m_t^G\right)$$

- p_t: vetor de parâmetros da política fiscal no trimestre t;
- τ_t^{INC}: alíquota do imposto de renda no trimestre t;
- τ_t^{VAT}: alíquota do imposto sobre valor agregado (IVA) no trimestre t;
- θ_t^{UB}: parâmetro do seguro-desemprego no trimestre t;
- $\log m_t^G$: logaritmo do multiplicador da demanda de consumo do governo no trimestre t;
- $\mathcal{P}$: conjunto de combinações de política fiscal admissíveis.

Após observar o estado s_t, o agente governamental escolhe um vetor de ajustes

$$a_t = \left(a_t^{\text{INC}}, a_t^{\text{VAT}}, a_t^{\text{UB}}, a_t^G\right) \in \mathcal{A}.$$

Esses ajustes determinam os parâmetros da política fiscal do trimestre seguinte:

$$p_{t+1} = (p_t + a_t), \qquad p_t = \left(\tau_t^{\text{INC}}, \tau_t^{\text{VAT}}, \theta_t^{\text{UB}}, \log m_t^G\right).$$

Os demais parâmetros do modelo serão mantidos os mesmos da calibração do BeforeIT.jl.

A função de recompensa refletirá o objetivo de maximizar o bem-estar da população através do aumento do PIB, da diminuição do desemprego, da convergência para a meta de inflação e da adequação às regras fiscais europeias de dívida e déficit público. Será dada por:

$$\begin{aligned} r_t = \alpha \log\left(\frac{Y_t^{\text{real}}}{Y_0^{\text{real}}}\right) - \beta u_t - \gamma|\pi_t - \pi^*| \\ - \lambda_d \left[\max\left(0, d_t - 0{,}03\right)\right]^2 \\ - \lambda_b \left[\max\left(0, b_t - b_t^{\text{meta}}\right)\right]^2. \end{aligned}$$

- r_t: recompensa no trimestre t;
- Y_t^{real}: PIB real no trimestre t;
- Y_0^{real}: PIB real inicial;
- u_t: taxa de desemprego;
- π_t: taxa de inflação;
- π^*: meta de inflação;
- p_t: vetor de parâmetros da política fiscal aplicado no trimestre t;
- p_{t-1}: vetor aplicado no trimestre anterior;
- d_t: déficit público acumulado nos últimos quatro trimestres dividido pelo PIB nominal acumulado no mesmo período; nos primeiros trimestres, usa-se a janela disponível;

- b_t: dívida pública ao fim do trimestre t dividida pelo PIB nominal anualizado a partir de até quatro trimestres;
- b_0: razão dívida/PIB no início da simulação;
- $b_t^{\text{meta}} = 0{,}60 + \max(0, b_0 - 0{,}60)\left(\frac{19}{20}\right)^{t/4}$: trajetória que reduz em 1/20 por ano a distância inicial da dívida à meta de 60% do PIB;
- $\alpha, \beta, \gamma, \lambda_d, \lambda_b > 0$: pesos dos componentes da recompensa.

Um tema em aberto é a definição dos pesos da função de recompensa, que será elaborado durante a execução do projeto.

No treinamento, o agente atualizará a sua função de valor Q de acordo com a seguinte equação de Bellman:

$$Q(s_{i,t}, a_{i,t}) \leftarrow (1-\alpha)Q(s_{i,t}, a_{i,t}) + \alpha\left(r_{i,t} + \gamma \max_{a \in \mathcal{A}} Q(s_{i,t+1}, a)\right)$$

Em que *alpha* é a taxa de aprendizado e *gamma* é o fator de desconto. Durante o treinamento, o agente seleciona suas ações segundo uma política ε-greedy:

$$a_{i,t} = \begin{cases} \text{uma ação aleatória}, & \text{com probabilidade } \varepsilon, \\ \arg\max\limits_{a \in \mathcal{A}} Q(s_{i,t}, a), & \text{caso contrário.} \end{cases}$$

O valor de ε diminuirá gradualmente ao longo dos episódios de treinamento. Após o treinamento, cada agente seguirá a política aprendida, escolhendo a ação que maximiza a função Q:

$$a_i^*(s) = \arg\max_{a \in \mathcal{A}} Q_i(s, a).$$

Após o treinamento, os resultados serão interpretados para identificar estratégias e padrões da política fiscal e seus principais impactos nas variáveis agregadas de interesse, como PIB, inflação, dívida.

Além disso, serão explorados os comportamentos da política fiscal frente a choques exógenos, como diminuições na renda disponível para o consumo.

Análise de Sensibilidade

Antes do treinamento, será realizada uma análise de sensibilidade dos parâmetros da política fiscal através de simulações de Monte Carlo. Serão selecionadas N configurações por amostragem em hipercubo latino ("LHS"). Cada configuração será mantida fixa durante 12 trimestres, e seus resultados serão calculados com J sementes aleatórias comuns. Os pares formados pelos parâmetros e pelos resultados médios serão usados para estimar a influência de cada alavanca fiscal.

$$\{p_i\}_{i=1}^N = \text{LHS}(\mathcal{P}, N), \qquad \bar{\mathbf{y}}_{i,12} = \frac{1}{J}\sum_{j=1}^{J} S_{12}(p_i, \mathbf{x}_0, \varepsilon_j).$$

- p_i: vetor de parâmetros da configuração i;

- N: número de configurações amostradas;
- J: número de sementes por configuração;
- $\mathbf{x}_0$: estado inicial do modelo;
- ε_j: choques e sorteios associados à semente j;
- S_{12}: resultado do simulador após 12 trimestres;
- $\bar{\mathbf{y}}_{i,12}$: vetor médio de resultados da configuração i.

A análise de sensibilidade será uma primeira etapa informativa sobre o potencial impacto da política fiscal nas variáveis de interesse do modelo como inflação, crescimento do PIB, desemprego, déficit público e dívida do governo.

Todos os procedimentos destacados serão primeiramente realizados em uma escala reduzida do modelo (1:1000) e posteriormente serão reproduzidos e validados na escala 1:1 para a economia da Áustria.

Plano de atividades

Tabela 1: Plano de atividades por semestre

Atividade e método	**Entregável**	**Sem 1**	**Sem 2**	**Sem 3**	**Sem 4**
Revisão de literatura e documentação de funcionamento do modelo	Lacunas de pesquisa definidas	X			
Realizar análise de sensibilidade nos parâmetros fiscais do modelo	Intervalos viáveis de ajuste na política fiscal e seus respectivos efeitos	X	X		
Definir objetivo da política fiscal	Critérios de avaliação definidos		X		
Desenvolver agente governamental usando aprendizagem por reforço	Treinar política e documentar decisões			X	
Testar políticas em novas simulações, com e sem choques econômicos, comparando resultados e incertezas	Resultados de bem-estar, fiscais e robustez			X	X
Consolidar resultados, qualificar e finalizar a escrita	Qualificação e defesa	X	X		X

5 Resultados parciais

Resultados Parciais da Análise de Sensibilidade

Na escala de 1:1000, os parâmetros fiscais foram variados de 0% a 200% dos valores calibrados para a Áustria. As figuras apresentam a variação percentual do PIB real em relação à configuração de base e as associações entre parâmetros e indicadores no 12º trimestre.

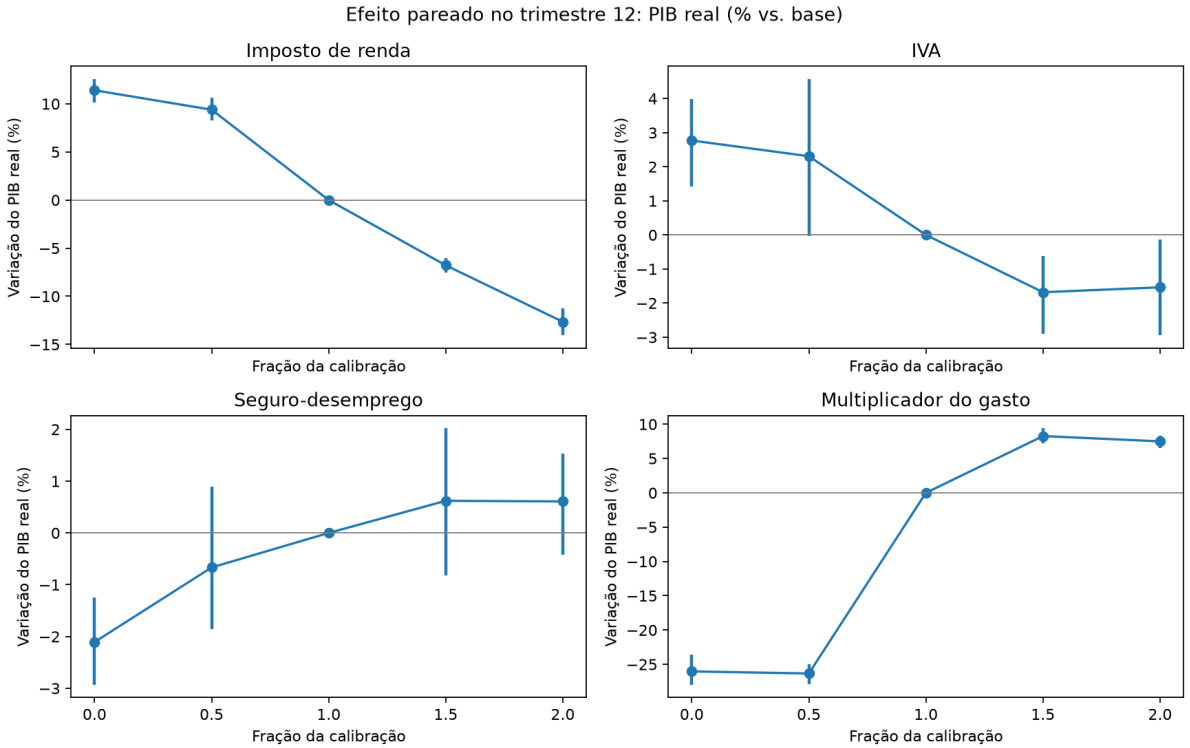


Figura 1: Efeito pareado dos parâmetros fiscais sobre a variação percentual do PIB real no 12º trimestre; as barras indicam a incerteza das estimativas.

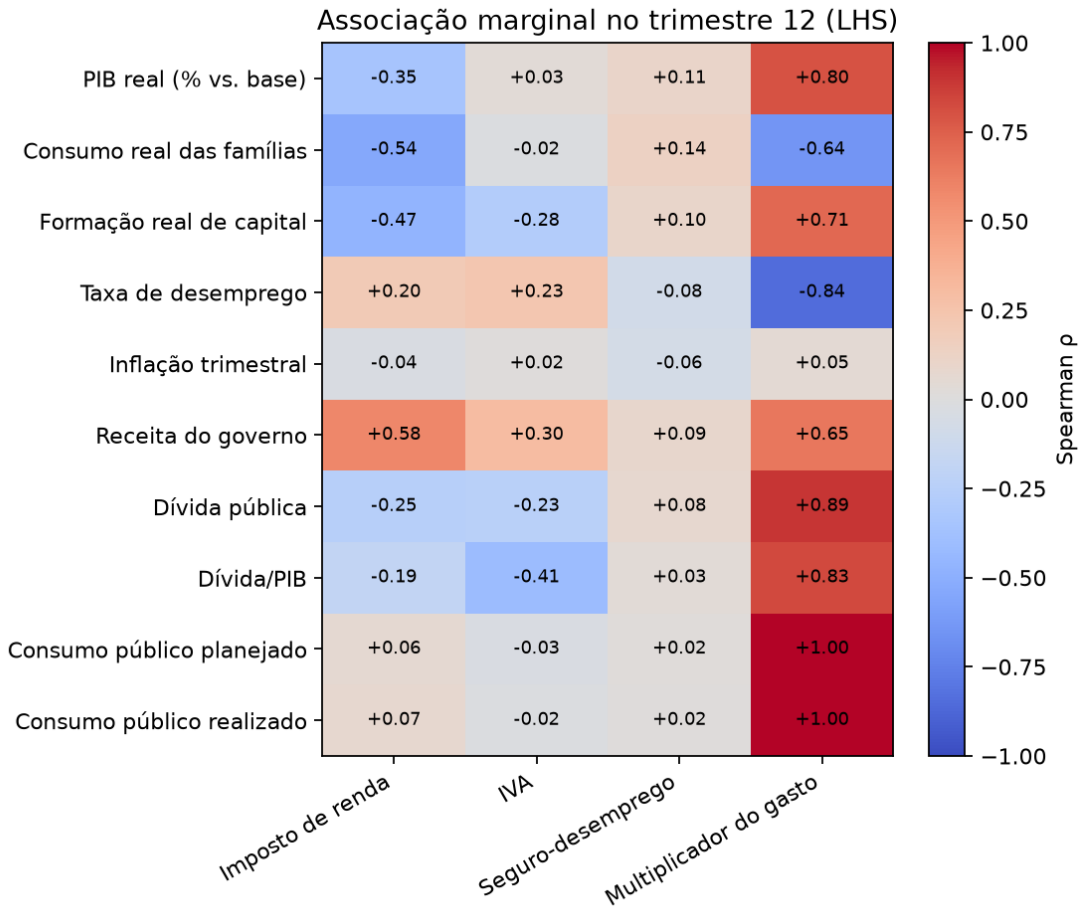


Figura 2: Correlações de Spearman entre os parâmetros fiscais e os indicadores econômicos no 12º trimestre, na amostragem por hipercubo latino.

Pontos para comentar nos resultados

- Destaque a resposta não linear do PIB ao multiplicador do gasto, sobretudo entre 50% e 100% da calibração.
- Relacione a associação positiva do multiplicador do gasto com o PIB à sua associação positiva com a dívida pública.
- Comente que o aumento do imposto de renda reduz o PIB no experimento pareado, enquanto sua redução o eleva.
- Aponte que os efeitos do IVA e do seguro-desemprego sobre o PIB são menores e apresentam maior incerteza.
- Explique que o gráfico pareado compara alterações isoladas, enquanto as correlações do hipercubo latino mostram associações sob variação conjunta dos parâmetros.
- Delimite as conclusões à calibração austríaca, à escala de 1:1000 e ao horizonte de 12 trimestres.

Referências bibliográficas

ANGIONE, Claudio; SILVERMAN, Eric; YANESKE, Elisabeth. Using machine learning as a surrogate model for agent-based simulations. *PLOS ONE*, v. 17, n. 2, e0263150, 2022. DOI: https://doi.org/10.1371/journal.pone.0263150.

ARTHUR, W. B. *Complexity Economics: A Different Framework for Economic Thought*. Santa Fe Institute Working Paper, 2013. Disponível em: https://sites.santafe.edu/~wbarthur/Papers/Comp.Econ.SFI.pdf.

BRUSATIN, Simone; PADOAN, Tommaso; COLETTA, Andrea; DELLI GATTI, Domenico; GLIELMO, Aldo. Simulating the Economic Impact of Rationality through Reinforcement Learning and Agent-Based Modelling. In: *Proceedings of the 5th ACM International Conference on AI in Finance*. ACM, 2024. p. 159–167. DOI: https://doi.org/10.1145/3677052.3698621.

DAWID, Herbert; DELLI GATTI, Domenico. Agent-Based Macroeconomics. In: *Handbook of Computational Economics*. Elsevier, 2018. v. 4, p. 63–156. DOI: https://doi.org/10.1016/bs.hescom.2018.02.006.

DOSI, Giovanni; FAGIOLO, Giorgio; NAPOLETANO, Mauro; ROVENTINI, Andrea; TREIBICH, Tania. Fiscal and monetary policies in complex evolving economies. *Journal of Economic Dynamics and Control*, v. 52, p. 166–189, 2015. DOI: https://doi.org/10.1016/j.jedc.2014.11.014.

GALLEGATI, Mauro; KIRMAN, Alan. Reconstructing Economics: Agent Based Models and Complexity. *Complexity Economics*, v. 1, n. 1, p. 5–31, 2012. DOI: https://doi.org/10.7564/12-COEC2.

GLIELMO, Aldo; DEVETAK, Mitja; MELIGRANA, Adriano; POLEDNA, Sebastian. BeforeIT.jl: High-Performance Agent-Based Macroeconomics Made Easy. *arXiv*, arXiv:2502.13267, 2025. DOI: https://doi.org/10.48550/arXiv.2502.13267. Preprint.

LI, Nian; GAO, Chen; LI, Mingyu; LI, Yong; LIAO, Qingmin. EconAgent: Large Language Model-Empowered Agents for Simulating Macroeconomic Activities. *arXiv*, arXiv:2310.10436, 2024. DOI: https://doi.org/10.48550/arXiv.2310.10436. Preprint.

NEWMAN, M. E. J. *Complex Systems: A Survey*. arXiv:1112.1440, 2011. Disponível em: https://arxiv.org/abs/1112.1440.

POLEDNA, Sebastian; MIESS, Michael Gregor; HOMMES, Cars; RABITSCH, Katrin. Economic forecasting with an agent-based model. *European Economic Review*, v. 151, art. 104306, 2023. DOI: https://doi.org/10.1016/j.euroecorev.2022.104306.

ZHENG, Stephan; TROTT, Alexander; SRINIVASA, Sunil; PARKES, David C.; SOCHER, Richard. The AI Economist: Taxation policy design via two-level deep multiagent reinforcement learning. *Science Advances*, v. 8, n. 18, eabk2607, 2022. DOI: https://doi.org/10.1126/sciadv.abk2607.