AdaptGov: aprendizado de política fiscal adaptativa em um modelo macroeconômico baseado em agentes

Daniel Andrade

Outrubro de 2026

1 Introdução, objetivos e justificativa

1.1 Introdução

Um sistema complexo é caracterizado por possuir muitos agentes interagindo de forma a produzir comportamentos emergentes, ou seja, que não podem ser trivialmente derivados a partir de seus comportamentos individuais (Newman, 2011). Estes fenômenos emergentes por sua vez afetam os agentes individualmente, criando retroalimentações ("feedbacks") positivas e negativas.

A economia é um sistema complexo onde bilhões de agentes, entre trabalhadores, empresas, bancos e instituições governamentais, interagem resultando em fenômenos emergentes como preços, inflação, produto interno e crescimento. Além disso, esses atores aprendem e evoluem ao longo do tempo, o que modifica fundamentalmente a estrutura do sistema, tornando-o adaptativo (Arthur, 2013).

A aplicação da lente teórica de sistemas complexos adaptativos para o estudo da economia tem se mostrado uma alternativa promissora ao paradigma predominante da teoria econômica, o neoclássico, que se âncora em pressupostos teóricos pouco críveis, como a existência de um equilíbrio, as expectativas racionais e os agentes representativos (Gallegati e Kirman, 2012).

Nesse sentido, o campo da economia complexa ("complexity economics"), seria uma formulação mais geral da economia neoclássica, pois estuda as estruturas econômicas a partir de premissas menos restritas (Arthur, 2013).

Os modelos baseados em agentes ("ABMs") tem se constituído uma ferramenta poderosa para o estudo da economia complexa através de ferramentas computacionais (Dawid e Delli Gatti, 2018). Neles, os agentes econômicos são simulados através regras comportamentais que regem tanto seu comportamento individual quanto suas interações, sem a necessidade de um controle central. As variáveis agregadas resultantes emergem como resultado do computacional dos comportamentos e interações ao longo do tempo, sem a utilização de pressupostos de equilíbrio, informação e racionalidade perfeita e sem um controle central.

O trabalho proposto por Poledna et. al (Poledna et al., 2023), é um modelo baseado em agentes para a macroeconomia, ou seja, focado no estudo de propriedades agregadas da economia, como inflação, PIB, crescimento, desemprego (Dawid e Delli Gatti, 2018), em particular para a Áustria, que é um país pequeno, industrial e com economia aberta. Ele

é constituído por um modelo ancorado nas estatísticas nacionais e em regras autoregressivas de primeira ordem que realizou previsões macroeconômicas comparávais aos modelos DSGE ("Dynamic Stochastic General Equilibrium"), representante do paradigma atual da macroeconomia neoclássica. O BeforeIT.jl oferece uma implementação aberta e extensível deste modelo na linguagem Julia feita pela equipe de tecnologia da informação do Banco da Itália (Glielmo et al., 2025).

Novos trabalhos têm alavancado o campo da inteligência artificial ("IA") para construir modelos macroeconômicos baseados em agentes. Em (Zheng et al., 2022) e (Brusatin et al., 2024) técnicas de aprendizado por reforço são utlizadas para treinar agenetes com comportamentos racionais e avaliar o resultado macroeconômico. Em (Li et al., 2024) LLMs ("Large Language Models") fazem o papel de consumidores e trabalhadores em um modelo que busca reproduzir qualitativamente fatos estilizados macroeconômicos.

A análise de sensibilidade e os metas modelos tem se constituído uma ferramenta importante para a avaliação e emulação de ABMs em diversas áreas , pois podem oferecer maior robustez e explicabilidade aos resultados dos modelos em questão(Angione et al., 2022).

Dessa maneira, por ser um modelo extensível e com performance similar aos DSGEs, o Before.IT pode ser utilzado como plataforma para a exploração de políticas fiscais alteranativas, que combinam análise de sensibilidade, meta modelos e aprendizagem por reforço, avaliando-as contra regras fixas ou simples, frente medidas bem definidas de bem-estar, dívida pública e robustez. Esse tipo de exploração, pode ser um passo importante para tornar os ABMs macroeconômicos úteis ao auxiliar tomadores de decisões governamentais na formulação de políticas públicas.

1.2 Perguntas de Pesquisa

Pergunta central

No modelo BeforeIT.jl calibrado para a Áustria, uma política fiscal adaptativa treinada com aprendizado por reforço proporciona maior bem-estar que políticas de parametros fixos ou regras simples de ajuste, mantendo a dívida pública e a estabilidade macroeconômica sob limite definidos?

Perguntas secundárias

- Quais alterações nos parâmetros da política fiscal produzem resultados estatisticamente significantes?
- Qual a precisão um metamodelo treinado a partir dos parâmetros de política fiscal para reproduzir os indicadores do BeforeIT.jl?
- Como os resultados de uma política fiscal adaptativa se comparam as regras fixas e políticas fiscais?

1.3 Justificativa

Modelos baseados em agentes são uma ferramenta poderosa para a análise da macroeconomia com o potencial de informar a sociedade e agencias governamentais sobre o

comportamento passado e futuro de indicadores chaves como inflação, desemprego, crescimento (Arthur, 2013; Gallegati e Kirman, 2012; Dawid e Delli Gatti, 2018).

Nesse cenário, a construção de análise de sensibilidade e metamodelos são ferramentas importantes para avaliar a validade, explicabilidade e robustez dos modelos em questão.

Além disso, os modelos baseados em agentes tem tido sua fronteira explorada através da utilização de inteligência artificial para a construção de agentes adaptativos que aprendem ao longo da simulação(Angione et al., 2022; Zheng et al., 2022).

Este trabalho busca contribuir para o campo dos modelos macroeconomico baseados em agentes ao explorar um modelo de fronteira, construindo, validando e interpretando políticas fiscais adaptativa construídas através de metamodelos e aprendizagem por reforço. Assim, busca-se extender a aplicação do modelo de um papel preditivo para também um papel informativo sob eventuais políticas fiscais a serem aplicadas por um formulador de política economica.

1.4 Objetivos

Objetivo geral:

Desenvolver e avaliar políticas fiscais adaptativas no modelo Before.IT, calibrado para Áustria, através de técnicas de análise de sensibilidade, meta modelos e aprendizagem por reforço, comparando-as com políticas de parametros fixos e regras simples, quanto a bem-estar, dívida pública e estabilidade macroeconômica.

Objetivos específicos:

- Formular o problema de política fiscal no contexto do modelo Before.IT, com seus parâmetros, variáveis livres e restrições.
- Realizar análise de sensibilidade nas variáveis de estudo do problema de fiscal quantificando seus efeitos nos indicadores de avaliação selecionados.
- Construir e validar um metamodelo para estimar os resultados de simulações com parâmetros fiscais fixos e variáveis.
- Propor, treinar e avaliar um modelo de aprendizado por reforço para a política fiscal.
- Avaliar e interpretar os resultados considerando bem-estar, dívida pública e estabilidade macroeconômica.

2 Revisão bibliográfica

Uma revisão geral sobre o campo de estudo dos sistemas complexos pode ser econtrada em (Newman, 2011), que os conceitua como sistemas onde muitos atores interagem formando comportamentos que não podem ser explicados por suas ações individuais, chamados de emergentes.

Em (Arthur, 2013), (Gallegati e Kirman, 2012) e (Dawid e Delli Gatti, 2018) é possível encontrar uma conexão entre sistemas complexos e as ciências economicas. Em especial, a

abordagem de sistemas complexos para a economia é colocada como visão não reducionista e não axiomática, onde se estuda a interações economicas deses agentes.

A modelagem baseada em agentes para economia ("Agent-based Computational Economics") é definida em (Dawid e Delli Gatti, 2018) como o estudo computacional de processos economicos modelados a partir de sistemas dinamicos de agentes interativos.

Em (Poledna et al., 2023) foi construído um ABM de previsão macroeconômica para a economia da Áustria. Em (Glielmo et al., 2025) esse trabalho foi adaptado para a linguagem julia e disponibilidado de maneira open source.

Em (Zheng et al., 2022), (Zheng et al., 2022) e (Brusatin et al., 2024) é possível encontrar exemplos da aplicação de ferramentas de IA, como LLMs e aprendizagem por reforço, para aplicações em ABMs macroeconômicos. Em (Angione et al., 2022) ferramentas de IA são utilizadas para a construção de metamodelos.

3 Modelo de referência

As principais motivações do modelo BeforeIT.jl são:

- Realizar 'previsões macroeconômicas' utilizando modelagem baseada em agentes.
- Construir uma modelagem verossimilhante, calibrando o modelo de acordo com as estatísticas governamentais e executando a simulação com escala 1:1 da população do país.

O modelo inicial foi calibrado para a economia da Áustria, que é um país pequeno e altamente integrado com a economia externa ($\approx 9M$ habitantes e $\approx 50\%$ do PIB em importações/exportações). Os agentes do modelo são famílias ativas e invativas, empresas e empresários, governo, um banco comercial, um banco central e empresas extrangeiras.

Cada etapa temporal do modelo equivale a um 'trimestre'. As etapas-chave que levam o modelo de t para $t + 1$ são:

1. **Formação de expectativas coletivas:** nesta etapa é realizada uma regressão de primeira ordem para a previsão do PIB e da inflação. Essas previsões são utilizadas pelos diversos agentes, como empresas para estimar a produção do próximo ciclo e consumidores para estimar a renda do próximo ciclo.
2. **Execução dos choques exógenos:** nesta etapa são sorteados choques exógenos que modelam demanda e oferta do resto do mundo, ou seja, que quantificam as importações e exportações, bem como a inflação da zona do euro.
3. **Execução dos mercados de crédito e trabalho:** nesta etapa as empresas, após determinarem seus planos de produção, determinam o quanto querem de crédito do banco comercial. O banco então fornece crédito em uma ordem aleatória às empresas, obedecendo as regras regulatórias de fornecimento de crédito. Depois, as empresas determinam o qual será a força de trabalho a ser contrada ou demitida, que é selecionada aleatóriamente.

4. **Execução dos mercados de bens:** inicialmente o mercado intra-empresas é executado através do mencanismo de busca e pareamento, onde, para cada bem desejado, a empresas consumidora é selecionada aleatoriamente e os fornecedores são selecionados de com probabilidade proporcional ao seu preço e tamanho. O mesmo processo é então repetido para os consumidores finais e empresas de bem de consumo.

5. **Atualização da contabilidade:** são atualizados os preços, rendas, saldos, impostos e agregados econômicos.

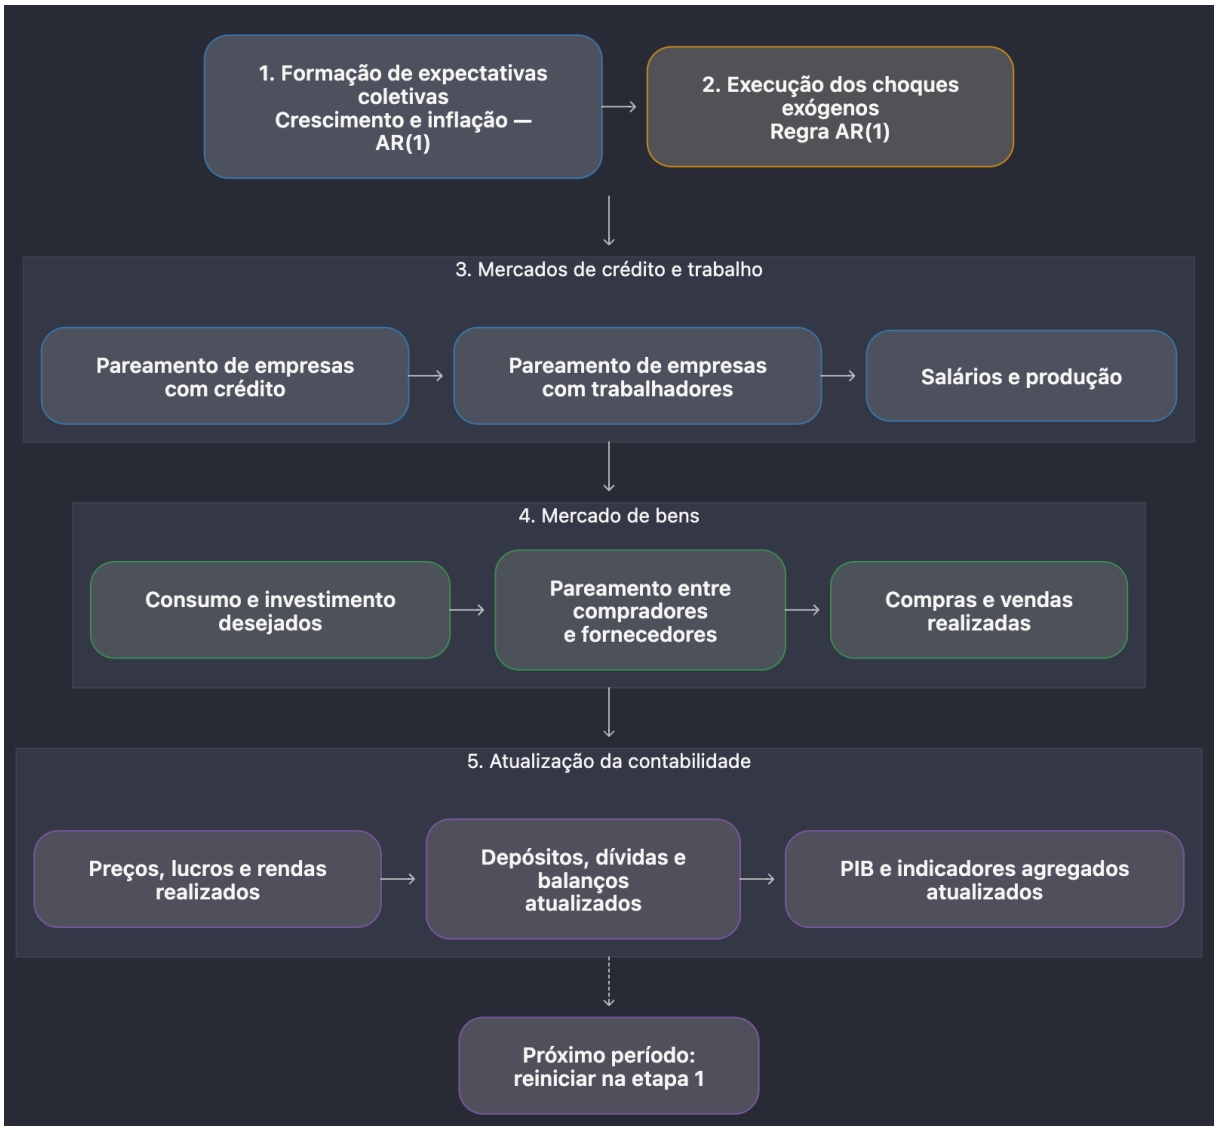


Figura 1: Fluxo de um período de simulação do modelo de referência.

4 Metodologia e plano de atividades

A pesquisa será baseada em simulações computacionais do modelo BeforeIT.jl calibrado para a Áustria. Os resultados da simulação, representados por $\mathbf{y}_{1:T}$, dependem dos parâmetros θ, do vetor de variáveis de estado iniciais $\mathbf{x}_0$ e dos choques aleatórios ε_t:

$$\mathbf{x}_{t+1} = F(\mathbf{x}_t, \theta, \varepsilon_{t+1}), \qquad \mathbf{y}_t = g(\mathbf{x}_t).$$

Para o estudo, selecionamos o cojunto dos parâmetros θ que interessam a política fiscal para serem explorados, a saber:

$$p = (\tau^{\text{INC}}, \tau^{\text{VAT}}, \theta^{\text{UB}}, \log m^G) \in \mathcal{P}.$$

- p: vetor de parâmetros da política fiscal;
- τ^{INC}: alíquota do imposto de renda;
- τ^{VAT}: alíquota do imposto sobre valor agregado (IVA);
- θ^{UB}: taxa de reposição do benefício de desemprego;
- $\log m^G$: logaritmo do multiplicador da demanda de consumo do governo;
- $\mathcal{P}$: conjunto de combinações de política fiscal admissíveis.

Nesse sentido, a política fiscal será definida como uma função que tem como entrada o estado do modelo no tempo anterior e saída o vetor de parâmetros da política fiscal:

$$\mu : \mathcal{X} \longrightarrow \mathcal{P}, \qquad p_t = \mu(\mathbf{x}_{t-1}) = (\tau_t^{\text{INC}}, \tau_t^{\text{VAT}}, \theta_t^{\text{UB}}, \log m_t^G).$$

Inicialmente, será realizada uma análise de sensibilidade dos parâmetros da política fiscal através de simulações de Monte Carlo. Serão selecionadas N configurações por amostragem por hipercubo latino ("LHS"). Cada configuração será mantida fixa durante 12 trimestres, e seus resultados serão calculados com J aletórias comuns. Os pares formados pelos parâmetros e pelos resultados médios serão usados para estimar a influência de cada alavanca fiscal.

$$\{p_i\}_{i=1}^N = \text{LHS}(\mathcal{P}, N), \qquad \bar{\mathbf{y}}_{i,12} = \frac{1}{J}\sum_{j=1}^{J} S_{12}(p_i, \mathbf{x}_0, \varepsilon_j).$$

- p_i: vetor de parâmetros da configuração i;
- N: número de configurações amostradas;
- J: número de sementes por configuração;
- $\mathbf{x}_0$: estado inicial do modelo;
- ε_j: choques e sorteios associados à semente j;

- S_{12}: resultado do simulador após 12 trimestres;
- $\bar{\mathbf{y}}_{i,12}$: vetor médio de resultados da configuração i.

A partir dos resultados da análise de sensibilidade, será construído um metamodelo que recebe o vetor p de parâmetros fiscais e prevê o vetor de indicadores ao final de $T = 12$ trimestres. A condição inicial será mantida fixa e serão considerados diversos modelos de aprendizagem, como regressões lineares, regressões gaussianas e redes neurais.

$$\bar{\mathbf{y}}_{i,T} = \frac{1}{J} \sum_{j=1}^{J} S_T(p_i, \mathbf{x}_0, \varepsilon_j), \qquad T = 12.$$

$$\hat{\mathbf{y}}_T(p) = \hat{f}(p).$$

$$\hat{f} = \arg\min_{f \in \mathcal{F}} \sum_{i=1}^{N} \|\mathbf{y}_{i,T} - f(p_i)\|_2^2 .$$

- p_i: vetor de parâmetros da política fiscal i;
- $\mathbf{x}_0$: estado inicial do modelo;
- $S_T(p_i, \mathbf{x}_0, \varepsilon_j)$: vetor de indicadores produzido pela simulação com a política i e a semente j;
- $\bar{\mathbf{y}}_{i,T}$: média desses indicadores entre as J sementes;
- $\hat{f}$: metamodelo ajustado aos pares $(p_i, \bar{\mathbf{y}}_{i,T})$;
- $\hat{\mathbf{y}}_T(p)$: previsão do metamodelo para a política p.

Em seguida será treinada uma política fiscal adaptativa utilizando apredizagem por reforço. Essa política terá como objetivo maximixar o bem-estar através da seguinte função de recompensa:

$$r_t = \alpha \log\left(\frac{Y_t^{\text{real}}}{Y_0^{\text{real}}}\right) - \beta u_t - \gamma|\pi_t - \pi^*| - \lambda_a \|p_t - p_{t-1}\|_2^2 .$$

- r_t: recompensa no trimestre t;
- Y_t^{real}: PIB real no trimestre t;
- Y_0^{real}: PIB real inicial;
- u_t: taxa de desemprego;
- π_t: taxa de inflação;
- π^*: meta de inflação;

- p_t: vetor de parâmetros da política fiscal aplicado no trimestre t;
- p_{t-1}: vetor aplicado no trimestre anterior;
- $\alpha, \beta, \gamma, \lambda_a > 0$: pesos dos componentes da recompensa.

Todos os procedimentos destacados serão primeiramente realizados em uma escala reduzida do modelo (1:1000) e posteriormente serão reproduzidos e validados na escala 1:1 para a economia da Áustria.

Tabela 1: Plano de atividades por semestre

Atividade e método	**Entregável**	**Sem 1**	**Sem 2**	**Sem 3**	**Sem 4**
Revisão de literatura e documentação de funcionamento do modelo	Lacunas de pesquisa definidas	X			
Realizar análise de sensibilidade nos parâmetros fiscais do modelo	Intervalos viáveis de ajuste na política fisscal e seus respectivos efeitos	X	X		
Definir objetivo da política fiscal e regras existentes com regras simples de ajuste	Critérios de avaliação definidos		X		
Avaliar o paper do aprendizado de máquina supervisionado e desenvolver agente governamental usando aprendizagem por reforço	Treinar política e documentar decisões			X	
Testar políticas em novas simulações, com e sem choques economicos, comparando resultados e incertezas	Resultados de bem-estar, fiscais e robustez			X	X
Consolidar resultados, qualifcar e finalizar escrita	Qualificação e defesa	X	X		X

5 Resultados parciais, se houver

Abaixo temos resultados parciais do treinamento de um metamodelo utilizando análise de sensibilidade em uma escala 1:1000.

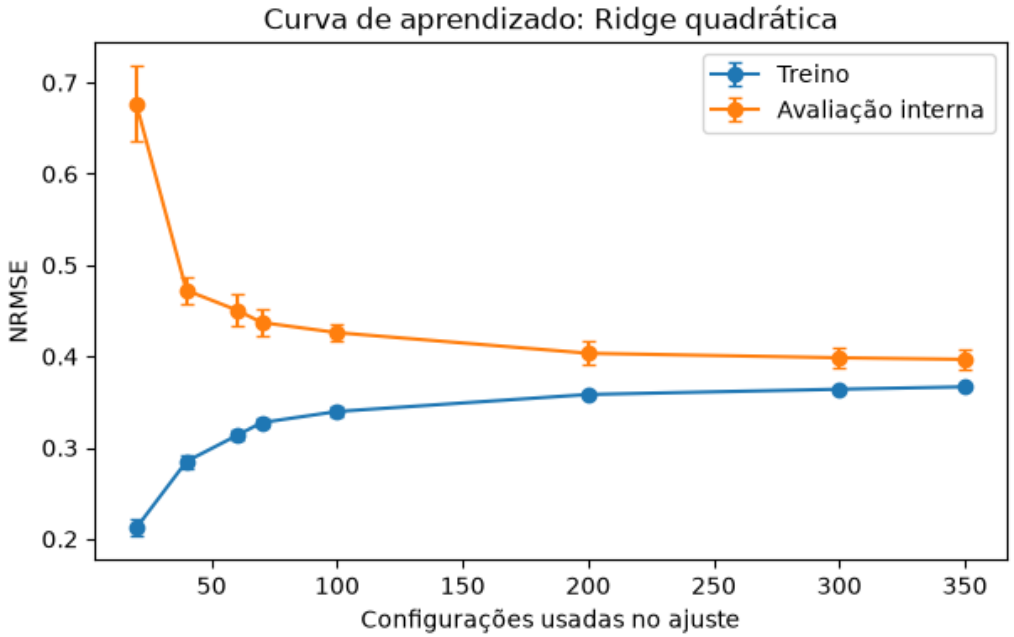


Figura 2: Curva de aprendizado da Ridge quadrática.

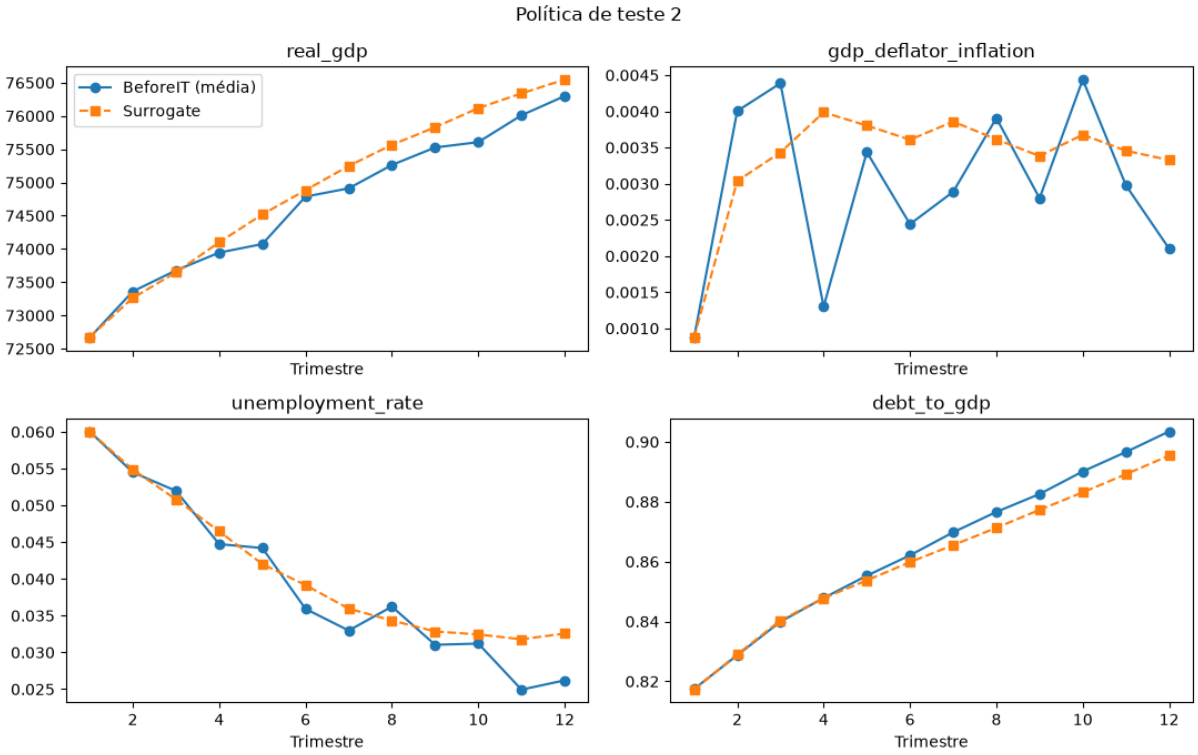


Figura 3: Trajetórias da política de teste 2: BeforeIT versus surrogate.

Referências bibliográficas

ANGIONE, Claudio; SILVERMAN, Eric; YANESKE, Elisabeth. Using machine learning as a surrogate model for agent-based simulations. *PLOS ONE*, v. 17, n. 2, e0263150, 2022. DOI: https://doi.org/10.1371/journal.pone.0263150.

ARTHUR, W. B. *Complexity Economics: A Different Framework for Economic Thought*. Santa Fe Institute Working Paper, 2013. Disponível em: https://sites.santafe.edu/~wbarthur/Papers/Comp.Econ.SFI.pdf.

BRUSATIN, Simone; PADOAN, Tommaso; COLETTA, Andrea; DELLI GATTI, Domenico; GLIELMO, Aldo. Simulating the Economic Impact of Rationality through Reinforcement Learning and Agent-Based Modelling. In: *Proceedings of the 5th ACM International Conference on AI in Finance*. ACM, 2024. p. 159–167. DOI: https://doi.org/10.1145/3677052.3698621.

DAWID, Herbert; DELLI GATTI, Domenico. Agent-Based Macroeconomics. In: *Handbook of Computational Economics*. Elsevier, 2018. v. 4, p. 63–156. DOI: https://doi.org/10.1016/bs.hescom.2018.02.006.

DOSI, Giovanni; FAGIOLO, Giorgio; NAPOLETANO, Mauro; ROVENTINI, Andrea; TREIBICH, Tania. Fiscal and monetary policies in complex evolving economies. *Journal of Economic Dynamics and Control*, v. 52, p. 166–189, 2015. DOI: https://doi.org/10.1016/j.jedc.2014.11.014.

GALLEGATI, Mauro; KIRMAN, Alan. Reconstructing Economics: Agent Based Models and Complexity. *Complexity Economics*, v. 1, n. 1, p. 5–31, 2012. DOI: https://doi.org/10.7564/12-COEC2.

GLIELMO, Aldo; DEVETAK, Mitja; MELIGRANA, Adriano; POLEDNA, Sebastian. BeforeIT.jl: High-Performance Agent-Based Macroeconomics Made Easy. *arXiv*, arXiv:2502.13267, 2025. DOI: https://doi.org/10.48550/arXiv.2502.13267. Preprint.

LI, Nian; GAO, Chen; LI, Mingyu; LI, Yong; LIAO, Qingmin. EconAgent: Large Language Model-Empowered Agents for Simulating Macroeconomic Activities. *arXiv*, arXiv:2310.10436, 2024. DOI: https://doi.org/10.48550/arXiv.2310.10436. Preprint.

NEWMAN, M. E. J. *Complex Systems: A Survey*. arXiv:1112.1440, 2011. Disponível em: https://arxiv.org/abs/1112.1440.

POLEDNA, Sebastian; MIESS, Michael Gregor; HOMMES, Cars; RABITSCH, Katrin. Economic forecasting with an agent-based model. *European Economic Review*, v. 151, art. 104306, 2023. DOI: https://doi.org/10.1016/j.euroecorev.2022.104306.

ZHENG, Stephan; TROTT, Alexander; SRINIVASA, Sunil; PARKES, David C.; SOCHER, Richard. The AI Economist: Taxation policy design via two-level deep multiagent reinforcement learning. *Science Advances*, v. 8, n. 18, eabk2607, 2022. DOI: https://doi.org/10.1126/sciadv.abk2607.